

ĐẠI HỌC QUỐC GIA TP HCM

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

KHOA CÔNG NGHỆ THÔNG TIN

XỬ LÝ NGÔN NGỮ TỰ NHIÊN

Báo cáo đồ án giữa kì

Đề tài: 28 - Vietnamese Chatbot history/traditional medical

Môn học: Nhập môn xử lý ngôn ngữ tự nhiên

Sinh viên thực hiện:

Nguyễn Đình Hà Dương

Lê Hoàng Minh Huy

Huỳnh Trung Kiệt

Đào Sỹ Duy Minh

Giáo viên hướng dẫn:

Assoc. Prof. Đinh Điền

TS. Nguyễn Hồng Bửu Long

Thầy Lê Đức Khoan

Ngày 28 tháng 7 năm 2026

Mục lục

1	Thông tin nhóm	3
1.1	Thành viên	3
1.2	Bảng phân công công việc	3
1.3	Tự đánh giá nhóm	3
2	Giới thiệu	5
2.1	Bối cảnh bài toán	5
2.2	Mục tiêu báo cáo giữa kì	5
3	Cách tiếp cận và phương pháp thực hiện	6
3.1	Ý tưởng tổng thể	6
3.2	Lý do lựa chọn phương pháp	6
4	Quy trình xử lý dữ liệu	7
4.1	Pipeline tổng thể	7
4.2	Mô tả các bước trong pipeline	7
5	Các bước chính	8
5.1	Tiền xử lý dữ liệu	8
5.2	OCR và trích xuất nội dung từ PDF	8
5.3	Hợp nhất và quản lý metadata	9
5.4	Chuẩn hóa sang Markdown và hậu xử lý nội dung	10
6	Công cụ và công nghệ sử dụng	10
6.1	Phân tích các mô hình và công cụ OCR	10
6.1.1	Giai đoạn đề xuất và khảo sát công cụ	10
6.1.2	DeepSeek OCR 3B	11
6.1.3	PaddleOCR	11
6.1.4	PDF-Extract-Kit	12

6.1.5	So sánh và lựa chọn công cụ	13
6.1.6	Đề xuất lựa chọn của nhóm	13
6.2	Công cụ kiểm tra và hiệu chỉnh chính tả (Gemini 3 Pro và Qwen 3 4B) . .	14
7	Thống kê	16
7.1	Sách: Những cây thuốc và vị thuốc Việt Nam	16
7.2	Sách: Chuẩn đoán và điều trị những bệnh cơ xương khớp thường gặp . . .	16
8	Ví dụ minh họa	17
8.1	Kết quả đầu ra của quá trình OCR bằng DeepSeek OCR 3B	17
8.1.1	Kết quả trên sách Những cây thuốc và vị thuốc Việt Nam	17
8.1.2	Kết quả trên sách Chuẩn đoán và điều trị những bệnh cơ xương khớp thường gặp	19
8.1.3	Nhận xét	21
8.2	Kết quả đầu ra của quá trình phân tích PDF bằng PDF-Extract-Kit . . .	21
8.3	Kết quả xuất tài liệu Word hoàn chỉnh	22
8.3.1	Kết quả	22
8.3.2	Nhận xét	23
8.4	Xây dựng và tổ chức Metadata tài liệu để sinh dữ liệu cho giai đoạn tiếp theo	23
8.5	Xây dựng và tổ chức Metadata tài liệu để sinh dữ liệu cho giai đoạn tiếp theo	23
9	Kết luận và hướng phát triển và kế hoạch tương lai	25
9.1	Kết luận	25
9.2	Hướng phát triển và kế hoạch tương lai	26
	Tài liệu tham khảo	28

1 Thông tin nhóm

1.1 Thành viên

Mã số sinh viên	Họ và tên
23122002	Nguyễn Đình Hà Dương
23122033	Lê Hoàng Minh Huy
23122039	Huỳnh Trung Kiệt
23122041	Đào Sỹ Duy Minh

1.2 Bảng phân công công việc

Thành viên	Nhiệm vụ	Đóng góp (%)
Nguyễn Đình Hà Dương	Xây dựng hệ thống trích xuất OCR sử dụng DeepSeek. Xây dựng metadata và chạy thử nghiệm trên một phần dữ liệu. Tham gia viết và hoàn thiện báo cáo.	100
Lê Hoàng Minh Huy	Xây dựng hệ thống trích xuất OCR sử dụng PDF-Extract-Kit. Xây dựng metadata và chạy thử nghiệm trên một phần dữ liệu.	100
Đào Sỹ Duy Minh	Xây dựng hệ thống kiểm tra chính tả và hoàn thiện tài liệu Word bằng mô hình ngôn ngữ lớn (LLM). Chạy và hoàn thành dữ liệu. Tham gia viết và hoàn thiện báo cáo.	100
Huỳnh Trung Kiệt	Xây dựng hệ thống kiểm tra chính tả và hoàn thiện tài liệu Word bằng mô hình ngôn ngữ lớn (LLM). Chạy và hoàn thành dữ liệu. Tham gia viết và hoàn thiện báo cáo.	100

Bảng 1: Phân công nhiệm vụ và mức độ đóng góp của các thành viên

1.3 Tự đánh giá nhóm

Nhóm đã hoàn thành đầy đủ các nội dung theo đúng tiến độ đề ra. Hệ thống trích xuất được xây dựng và triển khai ổn định, đáp ứng tốt các yêu cầu đặt ra về chất lượng, tính

chính xác và khả năng mở rộng. Quá trình làm việc nhóm được thực hiện nghiêm túc, phối hợp hiệu quả, đảm bảo tiến độ và chất lượng của đồ án.

2 Giới thiệu

2.1 Bối cảnh bài toán

Mục tiêu cuối cùng của đồ án là xây dựng một **chatbot hỏi–đáp dựa trên nội dung sách và giáo trình**. Tuy nhiên, dữ liệu của chatbot sẽ là những file PDF được scanned, những file PDF này biểu diễn dưới dạng hình ảnh và không có text layer.

Do đó, chatbot không thể trực tiếp đọc, tìm kiếm hay xử lý nội dung tài liệu. Để giải quyết vấn đề này, ta phải xây dựng một hệ thống thực hiện (**OCR**) nhằm chuyển đổi nội dung từ hình ảnh sang văn bản có thể xử lý tự động.

Vì vậy, trong phạm vi đồ án giữa kỳ, nhóm tập trung vào **trích xuất và tái tạo nội dung văn bản từ PDF quét bằng OCR**, làm tiền đề cho việc xây dựng chatbot ở các giai đoạn tiếp theo.

2.2 Mục tiêu báo cáo giữa kì

Mục tiêu của báo cáo là đề xuất, triển khai và đánh giá một hệ thống xử lý tự động cho bài toán chuyển đổi tài liệu **PDF dạng quét** sang **văn bản có cấu trúc** ở định dạng Word. Hệ thống được xây dựng nhằm **thỏa mãn đầy đủ các yêu cầu của đề bài**, đồng thời phục vụ cho việc khai thác và tái sử dụng nội dung tài liệu một cách hiệu quả.

Theo yêu cầu của đề bài, mỗi sinh viên thực hiện quá trình OCR tối thiểu **3000 câu** từ tài liệu PDF dạng quét. Kết quả đầu ra của hệ thống cần đáp ứng các tiêu chí sau:

- **Bảo toàn đầy đủ nội dung văn bản**, cho phép lược bỏ phần header và footer trong trường hợp không ảnh hưởng đến nội dung chính của tài liệu.
- **Bảo toàn đầy đủ hình ảnh, đồ thị và bảng biểu**; các thành phần này được lưu dưới dạng **file hình ảnh độc lập**, có đánh mã định danh và được **đính kèm đúng vị trí tương ứng** trong nội dung văn bản.

- **Giữ nguyên bố cục và cấu trúc tài liệu**, bao gồm thứ tự các đoạn văn, mục, tiểu mục và cách trình bày tổng thể của tài liệu gốc.
- Tại cuối mỗi chỉ mục cấp độ 2 (ví dụ: 2.1, 2.2, ...), **chèn chuỗi ký tự đặc biệt** `</break>` nhằm hỗ trợ cho bước tách mục trong quá trình hậu xử lý và tổ chức dữ liệu.
- **Định dạng đầu ra là file Word**, đảm bảo khả năng chỉnh sửa, khai thác và tích hợp vào các quy trình xử lý tiếp theo.
- Đề xuất sử dụng công cụ **EasyDataset** để hỗ trợ quá trình xử lý, tổ chức và quản lý dữ liệu OCR một cách hiệu quả.

3 Cách tiếp cận và phương pháp thực hiện

3.1 Ý tưởng tổng thể

Hệ thống được thiết kế theo kiến trúc pipeline, trong đó dữ liệu đầu vào là các tài liệu PDF scan. Quá trình trích xuất nội dung được thực hiện thông qua hai nhánh xử lý song song: (i) nhận dạng văn bản từ ảnh bằng OCR và (ii) trích xuất trực tiếp nội dung từ PDF trong trường hợp tài liệu có chứa lớp văn bản. Kết quả từ hai nhánh được hợp nhất và chuẩn hóa nhằm tạo ra biểu diễn thống nhất cho dữ liệu văn bản.


3.2 Lý do lựa chọn phương pháp

Việc áp dụng OCR đơn thuần thường dẫn đến nhiều hạn chế, bao gồm lỗi chính tả, mất dấu tiếng Việt và phá vỡ cấu trúc tài liệu. Do đó, hệ thống được mở rộng bằng cách kết hợp công cụ trích xuất PDF và sử dụng mô hình ngôn ngữ lớn (LLM) trong giai đoạn hậu xử lý. Cách tiếp cận này giúp tận dụng ưu điểm của từng phương pháp, đồng thời nâng cao độ chính xác, tính mạch lạc và mức độ hoàn thiện của văn bản đầu ra.

4 Quy trình xử lý dữ liệu

4.1 Pipeline tổng thể

Hình 1 trình bày pipeline tổng thể của hệ thống, mô tả toàn bộ quá trình xử lý từ tài liệu PDF scan đầu vào đến file Word có cấu trúc ở đầu ra. Pipeline được thiết kế theo hướng tuần tự kết hợp song song, nhằm tối ưu hóa chất lượng trích xuất nội dung và đảm bảo tính toàn vẹn của văn bản.



Hình 1: Pipeline xử lý tài liệu PDF scan sang Word

4.2 Mô tả các bước trong pipeline

Quy trình xử lý dữ liệu bao gồm các bước chính sau:

- **Chuyển đổi PDF scan sang ảnh:** Mỗi tài liệu PDF được tách thành các trang ảnh riêng lẻ nhằm phục vụ cho quá trình nhận dạng ký tự quang học.
- **Nhận dạng văn bản từ ảnh (OCR):** Các ảnh của từng trang được đưa vào mô hình chuyển xử lý về tác vụ OCR để trích xuất nội dung văn bản thô từ tài liệu hình ảnh được trích xuất ra từ văn bản scan.
- **Trích xuất nội dung từ PDF:** Trong trường hợp PDF có chứa lớp văn bản, hình ảnh, nội dung và thông tin cấu trúc được trích xuất trực tiếp nhằm bổ sung hình ảnh và đối chiếu với kết quả OCR.

- **Hợp nhất metadata:** Kết quả từ các nhánh xử lý được hợp nhất, kèm theo các metadata như văn bản đã OCR, số trang, ảnh và vị trí xuất hiện các đối tượng trong tài liệu.
- **Chuẩn hóa sang Markdown:** Văn bản sau khi được hợp nhất từ các nguồn khác nhau được chuyển đổi sang định dạng Markdown nhằm biểu diễn rõ ràng cấu trúc tài liệu, bao gồm tiêu đề, đoạn văn và các đối tượng hình ảnh, đồng thời xác định vị trí chèn phù hợp cho từng đối tượng.
- **Hậu xử lý bằng LLM và Human-in-the-loop:** LLM được sử dụng để sửa lỗi chính tả, khôi phục dấu tiếng Việt và cải thiện tính mạch lạc của nội dung văn bản. Sau đó dò và chỉnh sửa bằng tay những điểm mà LLM không thể sửa một cách chi tiết
- **Xuất file Word:** Nội dung Markdown cuối cùng được chuyển đổi sang định dạng Word, đảm bảo giữ nguyên cấu trúc và khả năng chỉnh sửa.

5 Các bước chính

5.1 Tiền xử lý dữ liệu

Các tài liệu PDF đầu vào chủ yếu tồn tại dưới dạng PDF scan, trong đó toàn bộ nội dung văn bản được lưu trữ dưới dạng hình ảnh. Do đó, bước tiền xử lý đóng vai trò quan trọng nhằm chuẩn bị dữ liệu phù hợp cho các bước trích xuất tiếp theo. Mỗi file PDF được tách thành các trang ảnh riêng lẻ, đảm bảo giữ nguyên thứ tự và mối quan hệ giữa các trang trong tài liệu gốc. Các ảnh sau khi tách được chuẩn hóa về kích thước để thực hiện OCR.

5.2 OCR và trích xuất nội dung từ PDF

Đối với các trang tài liệu đã được chuyển đổi sang dạng ảnh ở bước tiền xử lý, mô hình *DeepSeek OCR 3B* được sử dụng để thực hiện nhận dạng ký tự quang học và trích xuất nội dung văn bản thô. Mô hình này cho khả năng nhận dạng tương đối tốt đối với văn

bản in tiếng Việt, đồng thời xử lý hiệu quả các bố cục tài liệu phổ biến như đoạn văn và tiêu đề.

Tuy nhiên, mặc dù DeepSeek OCR cho chất lượng trích xuất văn bản cao, phương pháp này không bảo toàn được các thông tin về hình ảnh và layout của tài liệu gốc. Điều này gây hạn chế trong các bài toán yêu cầu tái hiện nội dung tài liệu một cách đầy đủ và có cấu trúc.

Để khắc phục nhược điểm trên, một framework xử lý song song, nhẹ, nhưng đảm bảo độ chính xác cao được xây dựng. Song song với quá trình OCR, *PDF-Extract-Kit* được sử dụng để trích xuất trực tiếp nội dung văn bản, hình ảnh và các thông tin cấu trúc từ file PDF gốc. Phương pháp này đặc biệt hiệu quả trong các trường hợp tài liệu chứa lớp văn bản (text layer) hoặc các thành phần đồ họa mà OCR không thể xử lý tốt.

Việc kết hợp hai hướng tiếp cận theo mô hình xử lý song song cho phép tận dụng ưu điểm của từng phương pháp: DeepSeek OCR đảm bảo chất lượng nhận dạng văn bản từ ảnh, trong khi PDF-Extract-Kit giúp bảo toàn hình ảnh và bố cục tài liệu. Cách tiếp cận này giúp giảm thiểu sai sót phát sinh khi chỉ sử dụng một nguồn trích xuất duy nhất, đồng thời nâng cao độ tin cậy và tính đầy đủ của dữ liệu đầu ra.

5.3 Hợp nhất và quản lý metadata

Sau khi hoàn tất quá trình trích xuất từ OCR và PDF, dữ liệu thu được từ hai nguồn được hợp nhất thành một biểu diễn thống nhất. Trong quá trình hợp nhất, các metadata quan trọng như số trang, thứ tự dòng, vị trí xuất hiện của văn bản và mối quan hệ giữa các thành phần nội dung được gán kèm nhằm bảo toàn cấu trúc và ngữ cảnh của tài liệu gốc.

Việc quản lý metadata không chỉ giúp duy trì tính toàn vẹn của tài liệu mà còn đóng vai

trò quan trọng trong các bước xử lý tiếp theo, đặc biệt là khi tái tạo bố cục tài liệu và đặt vị trí cho các đối tượng như hình ảnh hoặc bảng biểu trong file Word đầu ra.

5.4 Chuẩn hóa sang Markdown và hậu xử lý nội dung

Nội dung văn bản sau khi hợp nhất được chuyển đổi sang định dạng Markdown nhằm tạo ra một biểu diễn trung gian có cấu trúc rõ ràng và dễ xử lý. Markdown cho phép biểu diễn hiệu quả các thành phần như tiêu đề, đoạn văn, danh sách, bảng biểu và các công thức toán học, đồng thời hỗ trợ xác định vị trí chèn các đối tượng hình ảnh dựa trên metadata đã thu thập.

Định dạng Markdown cũng được lựa chọn nhằm tối ưu quá trình xử lý bằng mô hình ngôn ngữ lớn (LLM), do đây là định dạng văn bản nhẹ, dễ phân tích cú pháp và dễ tái cấu trúc.

Cuối cùng, kết quả sau hậu xử lý được rà soát và hiệu chỉnh thủ công ở những trường hợp đặc thù mà LLM chưa thể xử lý chính xác, nhằm đảm bảo chất lượng và độ tin cậy của tài liệu trước khi xuất ra định dạng Word.

6 Công cụ và công nghệ sử dụng

6.1 Phân tích các mô hình và công cụ OCR

6.1.1 Giai đoạn đề xuất và khảo sát công cụ

Trong giai đoạn đầu của đồ án, nhóm tiến hành khảo sát và đề xuất một số công cụ OCR phổ biến nhằm đánh giá mức độ phù hợp với bài toán trích xuất nội dung từ tài liệu PDF tiếng Việt. Các tiêu chí đánh giá chính bao gồm: khả năng nhận dạng tiếng Việt, hiệu quả với tài liệu scan, khả năng giữ cấu trúc văn bản, tốc độ xử lý và mức độ tùy chỉnh.

Dựa trên khảo sát ban đầu, nhóm tập trung phân tích ba hướng tiếp cận chính:

- Các mô hình OCR dựa trên Large Language Model (đại diện là DeepSeek OCR 3B).

- Các framework OCR truyền thống hiệu năng cao (đại diện là PaddleOCR).
- Các bộ công cụ trích xuất PDF tổng hợp (đại diện là PDF-Extract-Kit).

6.1.2 DeepSeek OCR 3B

DeepSeek OCR 3B là mô hình OCR dựa trên kiến trúc Large Language Model đa phương thức, được huấn luyện với quy mô lớn nhằm kết hợp khả năng nhận dạng ký tự và hiểu ngữ cảnh văn bản. Khác với các hệ thống OCR truyền thống chỉ tập trung vào nhận dạng ký tự, DeepSeek OCR có khả năng sinh văn bản mạch lạc và hỗ trợ suy luận ngữ nghĩa từ nội dung ảnh đầu vào.

Ưu điểm:

- Khả năng nhận dạng tiếng Việt tốt, đặc biệt với tài liệu in và văn bản học thuật.
- Hoạt động ổn định với tài liệu scan chất lượng trung bình, giảm phụ thuộc vào các bước tiền xử lý phức tạp.
- Có thể kết hợp với LLM để hiệu chỉnh lỗi OCR, tái cấu trúc đoạn văn và chuẩn hóa nội dung.
- Phù hợp với các pipeline xử lý tài liệu có bước hậu xử lý thông minh.

Nhược điểm:

- Chưa tối ưu cho các tài liệu có bố cục phức tạp như bảng biểu hoặc đa cột.
- Yêu cầu tài nguyên tính toán cao hơn so với các mô hình OCR truyền thống.

6.1.3 PaddleOCR

PaddleOCR là framework OCR mã nguồn mở được phát triển bởi Baidu, dựa trên nền tảng PaddlePaddle. Đây là một trong những giải pháp OCR phổ biến nhờ hiệu năng cao và khả năng hỗ trợ nhiều ngôn ngữ.

Ưu điểm:

- Tốc độ xử lý nhanh và ổn định trên nhiều loại tài liệu.
- Hỗ trợ tốt tiếng Việt, bao gồm cả văn bản in và văn bản ảnh chụp.
- Cung cấp pipeline OCR hoàn chỉnh từ phát hiện vùng chữ đến nhận dạng ký tự.

Nhược điểm:

- Kết quả đầu ra chủ yếu là văn bản thô, khả năng bảo toàn cấu trúc tài liệu còn hạn chế.
- Việc tinh chỉnh mô hình đòi hỏi kiến thức chuyên sâu về framework PaddlePaddle.

6.1.4 PDF-Extract-Kit

PDF-Extract-Kit là bộ công cụ mã nguồn mở chuyên dụng cho việc trích xuất nội dung từ tài liệu PDF, bao gồm cả PDF dạng text-based và image-based. Công cụ này tập trung vào phân tích bố cục tài liệu thay vì chỉ thực hiện OCR đơn thuần.

Ưu điểm:

- Khả năng phân tích và giữ cấu trúc tài liệu PDF tốt (tiêu đề, đoạn văn, bảng, hình ảnh).
- Cho phép kết hợp linh hoạt giữa OCR và trích xuất trực tiếp từ text-layer của PDF.
- Phù hợp với các tài liệu học thuật và báo cáo có bố cục phức tạp.

Nhược điểm:

- Chất lượng trích xuất phụ thuộc nhiều vào chất lượng PDF đầu vào.
- Không phải là mô hình OCR thuần túy mà là bộ công cụ tổng hợp, cần cấu hình nhiều thành phần.

6.1.5 So sánh và lựa chọn công cụ

Tiêu chí	DeepSeek OCR 3B	PaddleOCR	PDF-Extract- Kit
Khả năng tiếng Việt	Tốt	Trung bình	Không tốt
Xử lý tài liệu scan	Tốt	Trung bình	Trung bình
Giữ cấu trúc tài liệu	Trung bình	Thấp	Tốt
Tốc độ xử lý	Trung bình	Trung bình	Cao
Khả năng mở rộng	Cao	Cao	Trung bình
Mức độ tùy chỉnh	Cao	Trung bình	Cao
Mục tiêu sử dụng	OCR + hiểu ngữ nghĩa	OCR thuần túy	Trích xuất PDF toàn diện

6.1.6 Đề xuất lựa chọn của nhóm

Xuất phát từ yêu cầu xây dựng hệ thống có kiến trúc gọn nhẹ và thời gian trích xuất nhanh, sau quá trình khảo sát và so sánh các công cụ OCR, nhóm quyết định lựa chọn **DeepSeek OCR 3B kết hợp với PDF-Extract-Kit** cho hệ thống đề xuất. Trong đó, DeepSeek OCR 3B đảm nhiệm vai trò nhận dạng văn bản tiếng Việt và hỗ trợ hiệu chỉnh ngữ nghĩa, giúp cải thiện chất lượng nội dung trích xuất. Đồng thời, PDF-Extract-Kit được sử dụng để phân tích bố cục và bảo toàn cấu trúc tài liệu PDF. Sự kết hợp này cho phép hệ thống đạt được sự cân bằng giữa độ chính xác trong nhận dạng ký tự và khả năng trích xuất nội dung có tổ chức, đáp ứng hiệu quả yêu cầu xử lý các tài liệu học thuật tiếng Việt.

6.2 Công cụ kiểm tra và hiệu chỉnh chính tả (Gemini 3 Pro và Qwen 3 4B)

Bên cạnh bài toán nhận dạng ký tự quang học (OCR), một thách thức quan trọng trong quá trình trích xuất nội dung từ tài liệu PDF tiếng Việt là lỗi chính tả và lỗi ngữ nghĩa phát sinh sau OCR, đặc biệt đối với các tài liệu scan hoặc văn bản có chất lượng hình ảnh trung bình. Do đó, nhóm nghiên cứu xem xét bổ sung các mô hình ngôn ngữ lớn (LLM) nhằm thực hiện bước kiểm tra và hiệu chỉnh chính tả, cải thiện tính mạch lạc và độ tin cậy của văn bản đầu ra.

Trong giai đoạn khảo sát, hai mô hình được xem xét cho nhiệm vụ này là **Gemini 3 Pro** và **Qwen 3 4B**.

Gemini 3 Pro là mô hình ngôn ngữ lớn đa phương thức do Google phát triển, có khả năng hiểu ngữ cảnh tốt và hỗ trợ hiệu chỉnh văn bản ở mức độ ngữ nghĩa. Khi áp dụng cho văn bản sau OCR, Gemini 3 Pro có thể phát hiện và sửa các lỗi chính tả phổ biến, lỗi tách từ, cũng như cải thiện cấu trúc câu và đoạn văn.

Ưu điểm:

- Khả năng hiểu ngữ cảnh mạnh, phù hợp cho việc hiệu chỉnh văn bản dài và mang tính học thuật.
- Có thể tái cấu trúc câu, chuẩn hóa thuật ngữ và cải thiện tính mạch lạc của nội dung.

Nhược điểm:

- Phụ thuộc vào dịch vụ bên ngoài, không phù hợp với yêu cầu triển khai cục bộ (on-premise).
- Chi phí sử dụng cao và khó tích hợp vào pipeline xử lý gọn nhẹ.

Qwen 3 4B là mô hình ngôn ngữ lớn mã nguồn mở với kích thước trung bình, có thể triển khai cục bộ và tùy chỉnh theo nhu cầu. Mô hình này được đánh giá phù hợp cho các tác vụ như kiểm tra chính tả, sửa lỗi từ vựng và hiệu chỉnh câu ở mức cơ bản.

Ưu điểm:

- Có thể triển khai local, phù hợp với yêu cầu kiểm soát dữ liệu và tài nguyên.
- Hiệu năng chấp nhận được cho nhiệm vụ kiểm tra chính tả và hiệu chỉnh văn bản sau OCR.
- Dễ tích hợp vào pipeline xử lý tài liệu hiện có.

Nhược điểm:

- Khả năng hiểu ngữ nghĩa tiếng Việt chưa sâu bằng các mô hình thương mại lớn.
- Chủ yếu phù hợp cho sửa lỗi chính tả và lỗi câu đơn giản, chưa tối ưu cho tái cấu trúc văn bản phức tạp.

Nhìn chung, các công cụ kiểm tra chính tả dựa trên LLM đóng vai trò hỗ trợ quan trọng trong pipeline xử lý tài liệu. Tuy nhiên, trong phạm vi đồ án, nhóm không đặt trọng tâm vào việc hoàn thiện nội dung văn bản đầu ra về mặt ngữ nghĩa, mà ưu tiên độ chính xác của vị trí, bố cục và metadata phục vụ cho các bước xử lý tiếp theo. Do đó, các mô hình như Gemini 3 Pro và Qwen 3 4B được xem là các lựa chọn tiềm năng cho giai đoạn mở rộng trong tương lai, thay vì thành phần cốt lõi của hệ thống hiện tại.

7 Thống kê

7.1 Sách: Những cây thuốc và vị thuốc Việt Nam

Bảng 3:

Hạng mục	Số lượng
Tổng số trang xử lý	1297
Số trang Word sau xử lý	3419
Tổng số hình ảnh trích xuất	1096
Tổng số bảng trích xuất	33
Tổng số khối nội dung	1129

7.2 Sách: Chuẩn đoán và điều trị những bệnh cơ xương khớp thường gặp

Bảng 4: Sách: Thống kê kết quả xử lý tài liệu

Hạng mục	Số lượng
Tổng số trang xử lý	162
Số trang Word sau xử lý	201
Tổng số hình ảnh trích xuất	49
Tổng số bảng trích xuất	5
Tổng số khối nội dung	54

8 Ví dụ minh họa

8.1 Kết quả đầu ra của quá trình OCR bằng DeepSeek OCR 3B

8.1.1 Kết quả trên sách Những cây thuốc và vị thuốc Việt Nam

Kết quả minh họa nhận dạng văn bản từ mô hình DeepSeek OCR 3B trên trang 20 của tài liệu

bệnh khá mơ hồ như đau bụng, ho, hậu sản, cam, v.v... Trách nhiệm của người thầy thuốc là phải theo dõi tác dụng của thuốc trên lâm sàng, có đủ những xét nghiệm, phương tiện chẩn đoán hiện đại để dần dần có thể viết lại những tên bệnh, triệu chứng tật bệnh theo đúng như khoa học y học hiện đại. Có như vậy chúng ta mới thực hiện đúng chủ trương thừa kế nhưng phải phát huy hết vốn cũ của ông cha ta. Chúng ta không thể đứng ngoài mà chỉ trách các cụ lương y, các tài liệu y học cũ là lạc hậu, là mơ hồ để rồi không dùng, không theo, mà thái độ đúng của chúng ta là phải nghiên cứu tìm hiểu trên thực tế những tên bệnh đó tương ứng với những bệnh theo nghĩa khoa học y học hiện đại.

Để tiện cho các bạn tham khảo, đối chiếu, trong phạm vi có thể, ngoài những tên bệnh

mới, chúng tôi đều có ghi tác dụng và tính chất của vị thuốc theo các tài liệu cổ, theo tiếng nói của các cụ lương y. Kinh nghiệm bản thân tôi, là những tính chất và tác dụng đó tuy viết theo những danh từ cổ, nhưng cũng giúp ta một ý niệm quan trọng về những chỉ định của người xưa để có thể rút kinh nghiệm vận dụng trong điều kiện hiện nay.

Mặc dầu chúng tôi đã cố gắng để có nhiều tài liệu và dẫn chứng Việt Nam, nhưng chúng tôi vẫn tiếc rằng còn quá ít, vì phần lớn những kinh nghiệm dùng thuốc nam chưa được chính thức công bố.

Chúng tôi hy vọng rằng với chủ trương đầy mạnh sử dụng thuốc nam có theo dõi, tổng kết, tập tài liệu này sẽ ngày được bổ sung thêm nhiều những dẫn chứng và số liệu Việt Nam.

II. CƠ SỞ LÝ LUẬN VỀ TÌM THUỐC VÀ TÁC DỤNG CỦA THUỐC THEO ĐỒNG Y

A. Nguồn gốc phát hiện ra thuốc

Việc dùng thuốc trong nhân dân ta đã có từ lâu đời. Từ thời nguyên thủy, tổ tiên chúng ta trong lúc tìm kiếm thức ăn, có khi ăn phải chất độc phát sinh nôn mửa hoặc đi ỉa lỏng, hoặc hôn mê có khi chết người, do đó dần dần có nhận thức phân biệt được vị nào ăn được, vị nào có độc.

Kinh nghiệm dần dần tích lũy, không những giúp cho loài người biết lợi dụng tính chất của cây cỏ để làm thức ăn mà còn biết dùng làm thuốc chữa bệnh, hay dùng những vị có chất độc để chế tên thuốc độc dùng trong săn bắn hay trong lúc tự bảo vệ chống ngoại xâm. Lịch sử nước ta cho biết ngay từ khi lập nước nhân dân ta đã biết chế và sử dụng tên độc làm cho

bọn xâm lăng khiếp sợ.

Như vậy việc phát minh ra thuốc đã có từ thượng cổ, trong quá trình đấu tranh với thiên nhiên, tìm tòi thức ăn mà có được. Nguồn gốc tìm ra thức ăn, thuốc và cây cỏ chất độc chỉ là một. Về sau dần dần mới biết tổng kết và đặt ra lý luận. Hiện nay, do sâu vào tìm hiểu những kinh nghiệm chữa bệnh trong nhân dân Việt Nam, chúng ta có thể dễ dàng phân biệt hai loại người làm thuốc. Một loại chỉ có kinh nghiệm chữa bệnh, không biết hay ít biết lý luận, kinh nghiệm cổ cha truyền con nối mà tồn tại, mà phát huy, loại người này chiếm chủ yếu tại các vùng dân tộc ít người. Loại người thứ hai biết dùng thuốc nhưng thêm phần lý luận, loại này chiếm chủ yếu ở thành thị và những người có cơ sở lý luận cho rằng vua Thần Nông (1) là

(1) Thần Nông: Vị thần nông nghiệp của người Việt cổ trồng lúa nước. Một số học giả văn học dân gian Trung Quốc và Hoa Kỳ đã chứng minh Thần Nông là vị thần của cư dân phương Nam ngoài nước Trung Hoa cổ đại, là tổ tiên huyền thoại của vua Hùng. Thần Nông sinh ra Đế Minh, Đế Minh sinh ra Kinh Dương Vương, Kinh Dương Vương sinh ra Lạc Long Quân, Lạc Long Quân sinh ra vua Hùng người Việt cổ thời cùng cùng với Trời và thần Núi ở vị trí hiện nay của Đền Hùng (Tư điển bách khoa nông nghiệp-Hà nội, 1991).

Hình 2: Ảnh gốc trang 20

Page 20:


bệnh khá mơ hồ như đau bụng, ho, hậu sản, cam, v.v... Trách nhiệm của người thầy thuốc là phải theo dõi tác dụng của thuốc trên lâm sàng, có đủ những xét nghiệm, phương tiện chẩn đoán hiện đại để dần dần có thể viết lại những tên bệnh, triệu chứng tật bệnh theo đúng như khoa học y học hiện đại. Có như vậy chúng ta mới thực hiện đúng chủ trương thừa kế nhưng phải phát huy hết vốn cũ của ông cha ta. Chúng ta không thể đứng ngoài mà chỉ trách các cụ lương y, các tài liệu y học cũ là lạc hậu, là mơ hồ để rồi không dùng, không theo, mà thái độ đúng của chúng ta là phải nghiên cứu tìm hiểu trên thực tế những tên bệnh đó tương ứng với những bệnh theo nghĩa khoa học y học hiện đại.

Để tiện cho các bạn tham khảo, đối chiếu, trong phạm vi có thể, ngoài những tên bệnh mới, chúng tôi đều có ghi tác dụng và tính chất của vị thuốc theo các tài liệu cổ, theo tiếng nói của các cụ lương y. Kinh nghiệm bản thân tôi cho thấy những tính chất và tác dụng đó, tuy viết theo những danh từ cổ, nhưng cũng giúp ta một ý niệm quan trọng về những chỉ định của người xưa để có thể rút kinh nghiệm vận dụng trong điều kiện hiện nay.

Mặc dù chúng tôi đã cố gắng thu thập nhiều tài liệu và dẫn chứng Việt Nam, nhưng vẫn còn quá ít, vì phần lớn những kinh nghiệm dùng thuốc nam chưa được chính thức công bố.

Hình 3: Kết quả OCR bằng DeepSeek OCR 3B trên trang 20

sinh và chống lại nhau gọi là tương khắc.
 Trên cơ sở *sinh* và *khắc* lại thêm hiện tượng *chế hóa* và *tương thừa tương vũ*.
 Tương sinh, tương khắc, chế hóa, tương thừa tương và biểu thị mọi sự biến hóa phức tạp của sự vật.
Luật tương sinh. Tương sinh có nghĩa là giúp đỡ nhau để sinh trưởng. Dem ngũ hành liên hệ với nhau thì thấy 5 hành đó *quan hệ* với nhau, nương tựa lẫn nhau. Theo luật tương sinh thì thủy sinh mộc, mộc sinh hỏa, hỏa sinh thổ, thổ sinh kim, kim sinh thủy, thủy lại sinh mộc và cứ như vậy tiếp diễn mãi, thúc đẩy sự phát triển không bao giờ ngừng.
 Theo luật tương sinh của ngũ hành còn bao hàm ý nữa là hành nào cũng có *quan hệ* với hai phương diện: cái sinh ra nó và cái nó sinh ra tức là *quan hệ* mẫu tử. Ví dụ kim sinh thủy thì kim là mẹ của thủy, thủy lại sinh ra mộc vậy mộc là con của thủy.
 Trong quan hệ tương sinh lại có quan hệ tương khắc để biểu hiện cái ý *thắng* bằng, giữ gìn lẫn nhau.



Hình 4: Ảnh gốc trang 26

Page 26: sinh và chống lại nhau gọi là **tương khắc**. Trên cơ sở **sinh** và **khắc** lại thêm hiện tượng **chế hóa** và **tương thừa tương vũ**. Tương sinh, tương khắc, chế hóa, tương thừa tương vũ biểu thị mọi sự biến hóa phức tạp của sự vật. **Luật tương sinh.** Tương sinh có nghĩa là giúp đỡ nhau để sinh trưởng. Dem ngũ hành liên hệ với nhau thì thấy 5 hành đó *quan hệ* với nhau, nương tựa lẫn nhau. Theo luật tương sinh thì thủy sinh mộc, mộc sinh hỏa, hỏa sinh thổ, thổ sinh kim, kim sinh thủy, thủy lại sinh mộc và cứ như vậy tiếp diễn mãi, thúc đẩy sự phát triển không bao giờ ngừng. Trong luật tương sinh của ngũ hành còn bao hàm ý nữa là hành nào cũng có **quan hệ** về hai phương diện: cái sinh ra nó và cái nó sinh ra **tức** là *quan hệ* mẫu tử. Ví dụ kim sinh thủy thì kim là mẹ của thủy, thủy lại sinh ra mộc vậy mộc là con của thủy. Trong quan hệ tương sinh lại có quan hệ tương khắc để biểu hiện cái ý *thắng* bằng, giữ gìn lẫn nhau. **Luật tương khắc.** Tương khắc có nghĩa là ức chế và thắng nhau. Trong quy luật tương khắc thì mộc khắc thổ, thổ khắc thủy, thủy khắc hỏa, hỏa khắc kim, kim khắc mộc và mộc lại khắc thổ, và cứ như vậy tiếp diễn mãi.
 Trong tình trạng bình thường, sự tương khắc có tác dụng duy trì sự thăng bằng, nhưng nếu tương khắc thái quá thì lại làm cho sự biến hóa trở ngại khác thường.
 Tương khắc, mỗi hành cũng lại có hai quan hệ: giữa cái thắng nó và cái nó thắng. Ví dụ hành mộc thì nó khắc thổ, nhưng nó lại bị kim khắc nó.
 Hiện tượng tương khắc không tồn tại đơn độc; trong tương khắc đã có ngụ ý tương sinh, do đó vạn vật tồn tại và phát triển.
Luật chế hóa. Chế hóa là chế ưc là sinh hóa phối hợp với nhau. Trong chế hóa bao gồm cả hiện tượng tương sinh và tương khắc. Hai hiện tượng này gắn liền với nhau.
 Lễ tạo hóa không thể không có sinh mà cũng

Trong tình trạng bình thường, sự tương khắc có tác dụng duy trì sự thăng bằng, nhưng nếu tương khắc thái quá thì lại làm cho sự biến hóa trở ngại khác thường.
 Trong tương khắc, mỗi hành cũng lại có hai quan hệ: giữa cái thắng nó và cái nó thắng. Ví dụ hành mộc thì nó khắc thổ, nhưng nó lại bị kim khắc nó.
 Hiện tượng tương khắc không tồn tại đơn độc; trong tương khắc đã có ngụ ý tương sinh, do đó vạn vật tồn tại và phát triển.
Luật chế hóa. Chế hóa là chế ưc là sinh hóa phối hợp với nhau. Trong chế hóa bao gồm cả hiện tượng tương sinh và tương khắc. Hai hiện tượng này gắn liền với nhau.
 Lễ tạo hóa không thể không có sinh mà cũng

Hình 2

a. Ngũ hành tương sinh b. Ngũ hành tương khắc c. Quan hệ chế hóa

Hình 5: Kết quả OCR bằng DeepSeek OCR 3B trên trang 26

8.1.2 Kết quả trên sách Chuẩn đoán và điều trị những bệnh cơ xương khớp thường gặp

Kết quả minh họa nhận dạng văn bản từ mô hình DeepSeek OCR 3B trên trang 21 của tài liệu

2. Cấu trúc mô xương

Xương là một mô liên kết đặc biệt bao gồm các tế bào và chất khuôn xương (bone matrix). Chất khuôn xương bao gồm các sợi collagen và các mô liên kết khác giàu chất glucoaminoglycin, khuôn xương có thể trở thành calci hoá. Mô xương có xương đặc (xương vỏ) và xương xốp; 80%-90% khối lượng xương đặc được calci hoá; 15 - 25% khối lượng xương xốp được calci hoá. Xương đặc có chức năng bảo vệ còn xương xốp có chức năng chuyển hoá.

Các tế bào xương bao gồm: huỷ cốt bào là các tế bào khổng lồ đa nhân, có nhiệm vụ tiêu xương. Tạo cốt bào là tế bào có nhân hình thoi, có nhiệm vụ sản sinh ra các thành phần của nền xương (các sợi collagen và các chất nền), có vai trò quan trọng trong quá trình calci hoá.

Việc tạo xương (bone formation) và huỷ xương (bone resorption) diễn ra theo cơ chế thay xương cũ bằng xương mới. Bình thường hai quá trình này được duy trì một cách cân bằng cho đến khoảng 30 - 35 tuổi, từ tuổi này trở lên tạo cốt bào hoạt động quá mức, huỷ xương cao hơn tạo xương dẫn tới giảm khối lượng xương theo thời gian, đặc biệt ở giai đoạn mãn kinh, gây nên tình trạng loãng xương.

3. Khối lượng xương đỉnh (peak bone mass - PBM)

Là mật độ xương đạt được tối đa vào tuổi từ 20 - 35 (Tuy nhiên tuổi đạt được PBM tùy theo từng tác giả). PBM càng cao thì nguy cơ loãng xương sau này càng thấp.

Những yếu tố ảnh hưởng đến PBM:

- Di truyền: 60- 80% do yếu tố di truyền. Một số gen liên quan đến giảm MDX là những gen điều hoà sự tổng hợp collagen, các thụ thể estrogen, vitamin D.

19

Hình 6: Ảnh gốc trang 21

Page 21:

2. Cấu trúc mô xương

Xương là một mô liên kết đặc biệt bao gồm các tế bào và chất khuôn xương (bone matrix). Chất khuôn xương bao gồm các sợi collagen và các mô liên kết khác giàu chất glucoaminoglycin, khuôn xương có thể trở thành calci hoá. Mô xương có xương đặc (xương vỏ) và xương xốp; 80

Các tế bào xương bao gồm: huỷ cốt bào là các tế bào khổng lồ đa nhân, có nhiệm vụ tiêu xương. Tạo cốt bào là tế bào có nhân hình thoi, có nhiệm vụ sản sinh ra các thành phần của nền xương (các sợi collagen và các chất nền), có vai trò quan trọng trong quá trình calci hoá.

Việc tạo xương (bone formation) và huỷ xương (bone resorption) diễn ra theo cơ chế thay xương cũ bằng xương mới. Bình thường hai quá trình này được duy trì một cách cân bằng cho đến khoảng 30 - 35 tuổi, từ tuổi này trở lên tạo cốt bào hoạt động quá mức, huỷ xương cao hơn tạo xương dẫn tới giảm khối lượng xương theo thời gian, đặc biệt ở giai đoạn mãn kinh, gây nên tình trạng loãng xương.

3. Khối lượng xương đỉnh (peak bone mass - PBM)

Là mật độ xương đạt được tối đa vào tuổi từ 20 - 35 (Tuy nhiên tuổi đạt được PBM tùy theo từng tác giả). PBM càng cao thì nguy cơ loãng xương sau này càng thấp.

Những yếu tố ảnh hưởng đến PBM:

- Di truyền: 60-80 do yếu tố di truyền. Một số gen liên quan đến giảm MDX là những gen điều hoà sự tổng hợp collagen, các thụ thể estrogen, vitamin D.

19

Hình 7: Kết quả OCR bằng DeepSeek OCR 3B trên trang 21

Chú ý triệu chứng âm tính quan trọng là không có các vùng huỷ xương trên hình ảnh X-quang của thân đốt sống. Các đốt sống có mật độ đồng nhất, có kết đặc ở vùng mâm đốt sống (hình ảnh viền tang). Khe đĩa đệm không bị hẹp. Các cung sau hầu như bình thường.


Chỉ định X-quang cột sống: giảm chiều cao, gù vẹo cột sống, lâm sàng nghi ngờ có xẹp đốt sống.

Lưu ý:

- Cần nhớ: không phải tất cả các trường hợp gãy xương đều do loãng xương
- Cần nhắc Scan xương nếu gãy không rõ hoặc gãy do tác động gián tiếp
- Cần nhắc chụp MRI hoặc sinh thiết xương nếu nghi ngờ gãy gây liên quan đến carcinoma di căn
- Cần nhắc chụp MRI nếu nghi ngờ có di lệch sau hoặc bên

1.2.2. Phương pháp đo mật độ xương

1) Phương pháp hấp phụ năng lượng tia X kép (Dual Energy X-ray-Absorptionmetry - DEXA):



Hình 4. Đo hấp thụ tia X kép (DEXA)

24

Hình 8: Ảnh gốc trang 26

Page 26: Chú ý triệu chứng âm tính quan trọng là không có các vùng huỷ xương trên hình ảnh X-quang của thân đốt sống. Các đốt sống có mật độ đồng nhất, có kết đặc ở vùng mâm đốt sống (hình ảnh viền tang). Khe đĩa đệm không bị hẹp. Các cung sau hầu như bình thường.

Chỉ định X-quang cột sống: giảm chiều cao, gù vẹo cột sống, lâm sàng nghi ngờ có xẹp đốt sống.

Lưu ý:

- Cần nhớ: không phải tất cả các trường hợp gãy xương đều do loãng xương
- Cần nhắc Scan xương nếu gãy không rõ hoặc gãy do tác động gián tiếp
- Cần nhắc chụp MRI hoặc sinh thiết xương nếu nghi ngờ gãy liên quan đến carcinoma di căn
- Cần nhắc chụp MRI nếu nghi ngờ có di lệch sau hoặc bên

1.2.2. Phương pháp đo mật độ xương

1) Phương pháp hấp phụ năng lượng tia X kép (Dual Energy X-ray-Absorptionmetry - DEXA):
 Đo hấp thụ tia X kép (DEXA)

Những vị trí đo chính

Cột sống trước sau (PA) Đoạn gân (trên) xương đùi

Hình 4. Đo hấp thụ tia X kép (DEXA)

24

Hình 9: Kết quả OCR bằng DeepSeek OCR 3B trên trang 26

8.1.3 Nhận xét

- Mô hình DeepSeek OCR cho thấy chất lượng nhận dạng tiếng Việt tương đối tốt; tuy nhiên, đối với một số thuật ngữ khoa học hoặc từ chuyên ngành có cấu trúc phức tạp, độ chính xác vẫn còn hạn.
- Mặc dù layout của tài liệu phức tạp nhưng mô hình có thể nhận diện nội dung tốt. Mô hình có thể hiểu tốt tài liệu.
- Mặc dù chất lượng bản scan không cao (như minh họa trong Hình 4), nhờ việc áp dụng kiến trúc LLM, mô hình vẫn có khả năng suy luận và trích xuất nội dung văn bản gần như chính xác so với tài liệu gốc.
- Bên cạnh những ưu điểm về tốc độ và độ gọn nhẹ, mô hình hiện tại chưa hỗ trợ trích xuất hình ảnh, đây là một nhược điểm đáng chú ý của phiên bản OCR dung lượng nhỏ.

8.2 Kết quả đầu ra của quá trình phân tích PDF bằng PDF-Extract-Kit

Sau khi thực hiện phân tích tài liệu PDF bằng PDF-Extract-Kit, hệ thống sinh ra một tập các tệp đầu ra bao gồm hình ảnh, tệp văn bản định dạng Markdown (MD) và các tệp JSON trung gian.



Trong phạm vi nghiên cứu này, các tệp Markdown không được sử dụng để đánh giá nội dung do chất lượng chính tả tiếng Việt chưa đảm bảo độ tin cậy. Thay vào đó, nhóm tập trung khai thác các tệp hình ảnh được trích xuất cùng với thông tin vị trí của chúng trong tài liệu gốc, nhằm phục vụ cho việc xây dựng metadata và liên kết ngữ cảnh giữa hình ảnh và trang PDF tương ứng.

Cấu trúc thư mục đầu ra của PDF-Extract-Kit được tổ chức như sau:

```
output/
├── images/
│   ├── page_001_img_01.png
│   ├── page_001_img_02.png
│   ├── page_002_img_01.png
│   └── ...
├── result.md .....Nội dung văn bản trích xuất (không sử dụng do lỗi chính tả)
├── content.json .....Loại hình nội dung, văn bản, số trang, đường dẫn ảnh
├── layout.json .....Thông tin bố cục và tọa độ các khối
└── ...
```


8.3 Kết quả xuất tài liệu Word hoàn chỉnh

8.3.1 Kết quả




Hình 10: Trang Word nhóm trích xuất

Hình 11: Trang PDF



Hình 12: Trang Word – phần nội dung



Hình 13: Trang PDF

8.3.2 Nhận xét

Bằng công cụ nhóm sử dụng, hệ thống đã tái tạo gần như chính xác cấu trúc tài liệu gốc, bao gồm các khối nội dung và cách tổ chức bố cục. Đặc biệt, các vị trí ngắt trang (\break) được bảo toàn và chèn đúng theo yêu cầu của giảng viên, góp phần đảm bảo tính nhất quán và chuẩn mực của tài liệu đầu r

8.4 Xây dựng và tổ chức Metadata tài liệu để sinh dữ liệu cho giai đoạn tiếp theo

8.5 Xây dựng và tổ chức Metadata tài liệu để sinh dữ liệu cho giai đoạn tiếp theo

Nhằm phục vụ cho hai mục tiêu chính là *xây dựng bộ benchmark đánh giá hệ thống* và *phát triển mô-đun chatbox hỏi-đáp trên tài liệu*, nhóm tiến hành thiết kế và tổ chức lại

toàn bộ nội dung tài liệu dưới dạng **metadata có cấu trúc**. Việc chuẩn hóa dữ liệu ở mức metadata giúp hệ thống dễ dàng truy xuất, so khớp ngữ cảnh và mở rộng trong các giai đoạn xử lý tiếp theo.

Thay vì lưu trữ tài liệu dưới dạng văn bản thuần hoặc file PDF, mỗi trang tài liệu sau khi phân tích được biểu diễn dưới dạng một đối tượng JSON, trong đó nội dung được chia thành các khối (*text blocks*) có thứ tự logic rõ ràng. Mỗi khối dữ liệu được gán nhãn theo loại nội dung, bao gồm đoạn văn, hình ảnh và bảng biểu, đồng thời được liên kết với trang tương ứng trong tài liệu gốc.

Cấu trúc metadata được thiết kế sao cho phù hợp với bài toán xây dựng chatbox, cho phép hệ thống dễ dàng:

- Truy xuất nội dung theo số trang, loại dữ liệu hoặc thứ tự xuất hiện.
- Liên kết hình ảnh và bảng biểu với đoạn văn mô tả tương ứng.
- Phục vụ việc tạo tập dữ liệu benchmark cho các tác vụ truy vấn, hỏi-đáp và trích xuất thông tin.

Ví dụ về cấu trúc metadata của một trang tài liệu được mô tả như sau:

```
1 {  
2   "page_number": 20,  
3   "text": "Document content...",  
4   "text_blocks": [  
5     {  
6       "type": "image",  
7       "image_path": ".../images/img_20_3.png",  
8       "page_image_path":  
9       "caption": ""  
10      "bbox" :  
11    },  
12    {  
13      "type": "table",  
14      "caption": ""  
15    }  
  ]  
}
```

16

]

17

}

Trong cấu trúc trên, mỗi khối nội dung đều được gán thuộc tính **order** nhằm bảo toàn thứ tự xuất hiện trong tài liệu gốc. Đối với khối hình ảnh, ngoài đường dẫn ảnh và chú thích. Thông tin này đặc biệt quan trọng trong việc xác định ngữ cảnh phù hợp khi hệ thống chatbox cần trả lời các câu hỏi liên quan đến hình ảnh.

Nhờ cách tổ chức metadata theo hướng cấu trúc và giàu ngữ cảnh, dữ liệu đầu ra không chỉ phục vụ cho giai đoạn xây dựng chatbox mà còn có thể tái sử dụng cho các

9 Kết luận và hướng phát triển và kế hoạch tương lai

9.1 Kết luận

Đồ án đã đề xuất và triển khai một quy trình hoàn chỉnh cho bài toán trích xuất và tái tạo nội dung từ tài liệu PDF quét tiếng Việt. Quy trình này kết hợp giữa mô-đun nhận dạng ký tự quang học để trích xuất văn bản thô và mô-đun phân tích bố cục nhằm bảo toàn cấu trúc tài liệu, từ đó xây dựng metadata có tổ chức bao gồm văn bản, hình ảnh, bảng biểu và thông tin vị trí. Trên cơ sở metadata này, các mô hình ngôn ngữ lớn được sử dụng để hiệu chỉnh nội dung, tái cấu trúc và sinh ra tài liệu đầu ra có định dạng gần với bản gốc.

Kết quả thực nghiệm cho thấy phương pháp đề xuất giúp duy trì tương đối tốt bố cục tài liệu và vị trí các thành phần trực quan, đáp ứng yêu cầu chính của bài toán. Mặc dù chất lượng văn bản nhận dạng tiếng Việt còn tồn tại sai sót, đặc biệt ở mức ký tự và chính tả, nhưng việc tách biệt rõ ràng giữa giai đoạn trích xuất và giai đoạn tinh chỉnh đã giúp hệ thống đảm bảo tính linh hoạt, dễ mở rộng và có khả năng cải thiện trong các nghiên cứu tiếp theo.

9.2 Hướng phát triển và kế hoạch tương lai

Trong thời gian tới, hệ thống có thể được mở rộng và hoàn thiện theo các hướng nghiên cứu sau:

- **Xây dựng hệ thống hỏi–đáp dựa trên RAG (Retrieval-Augmented Generation):**

Phát triển cơ chế truy xuất tài liệu dựa trên biểu diễn embedding kết hợp với mô hình ngôn ngữ lớn để sinh câu trả lời, cho phép người dùng truy vấn trực tiếp trên tập tài liệu đã được xử lý với độ chính xác và tính liên quan cao hơn.

- **Xây dựng và đánh giá bộ dữ liệu tiếng Việt chuyên ngành:** Thu thập và xây dựng các bộ dữ liệu tiếng Việt mới, đặc biệt trong các lĩnh vực chuyên ngành như y tế, đồng thời đề xuất các bộ benchmark đánh giá riêng cho bài toán trích xuất và hỏi–đáp trên tài liệu tiếng Việt. Trên cơ sở đó, tiến hành tinh chỉnh (fine-tuning) các mô hình phù hợp nhằm nâng cao hiệu năng hệ thống.

- **Sinh dữ liệu hỏi–đáp tự động:** Nghiên cứu các phương pháp tự động sinh câu hỏi và câu trả lời từ tài liệu đã trích xuất nhằm mở rộng tập dữ liệu huấn luyện và đánh giá cho các bài toán hỏi–đáp, giảm sự phụ thuộc vào dữ liệu gán nhãn thủ công.

- **Tích hợp mô hình ngôn ngữ lớn chuyên ngành:** Khảo sát và tích hợp các mô hình ngôn ngữ lớn chuyên sâu theo từng lĩnh vực (ví dụ: y tế) để cải thiện độ chính xác, tính nhất quán và giá trị chuyên môn của các câu trả lời được sinh ra.

- **Mở rộng hình thức tương tác người–máy:**

- Hỗ trợ tương tác bằng giọng nói, cho phép người dùng thực hiện truy vấn và nhận phản hồi thông qua hội thoại âm thanh.
- Hỗ trợ truy vấn dựa trên hình ảnh thông qua các mô hình thị giác–ngôn ngữ, cho phép đặt câu hỏi trực tiếp trên hình ảnh, bảng biểu hoặc trang tài liệu.

- **Nâng cấp khả năng suy luận và hạ tầng hệ thống:** Phát triển cơ chế hội thoại nhiều lượt kết hợp với các chiến lược suy luận sâu, đồng thời xây dựng hạ tầng máy chủ phục vụ truy vấn thời gian thực và mở rộng quy mô hệ thống.
- **Cải thiện truy xuất và tái tạo bố cục tài liệu:** Trong các nghiên cứu tiếp theo, hệ thống truy xuất có thể được nâng cấp bằng các mô hình có quy mô lớn hơn, đồng thời cải thiện khả năng tái tạo tài liệu với bố cục rõ ràng, nhất quán và sát với tài liệu gốc hơn.

Những hướng phát triển này kỳ vọng sẽ góp phần hoàn thiện hệ thống đề xuất, đồng thời mở rộng khả năng ứng dụng trong các bài toán khai thác tri thức, trợ lý thông minh và hỗ trợ chuyên môn trên tập tài liệu tiếng Việt.

Tài liệu tham khảo

- [1] Du, Y., Li, C., Guo, R., Yin, X., Liu, W., Zhou, J. (2020). *PaddleOCR: An Ultra Lightweight Optical Character Recognition System*. arXiv preprint arXiv:2009.09941.
- [2] DeepSeek AI (2024). *DeepSeek OCR: High-Performance Multilingual Optical Character Recognition System*. Available at: <https://deepseekocr.dev>.
- [3] OpenDataLab (2023). *PDF-Extract-Kit: A Comprehensive Toolkit for PDF Content Extraction*. GitHub repository: <https://github.com/opendatalab/PDF-Extract-Kit>.
- [4] Qwen Team (2024). *Qwen: Advancing Open-Source Large Language Models*. arXiv preprint arXiv:2309.16609.

